Nombre: Maria Jose Pech

1. ¿Por qué el camino de 13 pasos, pegado al acantilado, es óptimo?

Porque es el camino más corto hacia la meta. Aunque está junto al acantilado, permite llegar en 13 pasos sin caer, obteniendo la mayor recompensa posible.

2. ¿Por qué la curva de entrenamiento queda por debajo de −13 aunque la política greedy ya sea óptima?

Porque durante el entrenamiento el agente todavía explora con una probabilidad \(\epsilon\), por lo que puede tomar acciones aleatorias y caer al acantilado. Estas caídas generan penalizaciones adicionales y hacen que la recompensa promedio sea menor que −13.

3. En el paso que cae al acantilado, ¿cuál es \(s'\) en el backup de Q-learning, y por qué ese backup no trata el acantilado como estado terminal?

El estado \(s'\) es el estado inicial, porque al caer al acantilado el agente recibe una penalización de −100 y regresa al inicio. No se considera terminal porque el episodio continúa; el estado terminal es la meta.